

Projeto de Aprendizagem da Máquina

...

Mariama Celi Serafim de Oliveira
Mélody Anne Marie Ballouard

Roteiro

- Introdução
- Visão geral
- Metodologia
- Resultados
- Discussão / Conclusão
- Bibliografia

Introdução

- Para cada jogo do “Tic-Tac-Toe”
 - Probabilidade que o jogo X seja ganhador
 - Probabilidade que ele seja perdedor.
- Vários classificadores usados:
 - Algoritmo Fuzzy
 - classificador Bayesiano, método dos k-vizinhos, regra da soma
 - MLP, SVM

Visão geral

- Algoritmo Fuzzy
- Classificador Bayesiano
- Método dos k-vizinhos
- Regra da soma
- MLP
- SVM

Metodologia

- A base de dados utilizados
 - Duas classes: Positive e Negative
 - Transformação da base de dados numa tabela
- O método do k-fold
 - K partições :
 - K-1 de treinamento
 - 1 de teste
 - Erro final = média do erro de cada experiência

Metodologia

- Friedman test com 5 classificadores e 10 conjuntos de dados.
- Parâmetros usados:
 - K-vizinhos: qual k produz o menor erro ?
 - MLP:
 - função de treinamento : gradiente descendente
 - Taxa de aprendizagem
 - número de nós na camada escondida
 - SVM: 4 funções de Kernel
 - linear, polynomial, radial basis, sigmoid

Resultados - Classificador Fuzzy & Bayesiano

- Fuzzy: Conjunto de Medoids:

- Classe 1: 124 e 687
- Classe 2: 319 e 329


Resumo dos valores obtidos pelo classificador Fuzzy	
Erro global	0.464509
Erro da classe 1	0.436102
Erro da classe 2	0.518072
Índice de Rand Corrigido	0.001540

- Bayesiano:

- Erro médio de 24.59%
- Intervalo de confiança ($0.239354 \leq \mu \leq 0.252435$) = 95%.

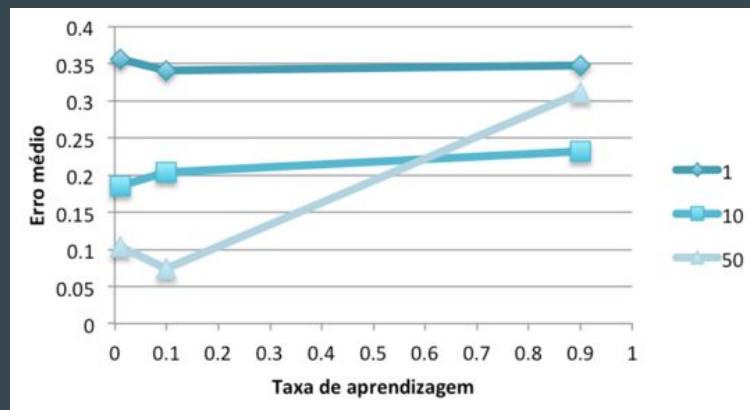
Resultados - Método dos k-vizinhos

- Comparamos o número de vizinho e o erro médio obtido no conjunto TicTacToe em uma validação cruzada 10x10.
- Melhor configuração com $k = 15$
- Erro médio = 0.028421
- Intervalo de confiança ($0.016759 \leq \mu \leq 0.040083$) = 95%



Resultados - Regra da soma & MLP

- Regra da Soma:
 - Usamos o classificador Bayesiano e o melhor k-vizinhos ($k=150$)
 - Erro médio = 0.102421
 - Intervalo de confiança = $(0.092963 \leq \mu \leq 0.111879) = 95\%$
- MLP
 - Intervalo de confiança = $(0.076753 \leq \mu \leq 0.095458) = 95\%$
 - Erro médio = 0.086105



Resultados - svm

Tipo de Kernel	Erro médio	Intervalo de confiança
Linear	0.339052	$(0.337473 \leq \mu \leq 0.340632) = 95\%$
Polinomial	0.228632	$(0.223299 \leq \mu \leq 0.233965) = 95\%$
Base radial	0.123789	$(0.118528 \leq \mu \leq 0.129050) = 95\%$
Sigmoidal	0.340947	$(0.339175 \leq \mu \leq 0.342719) = 95\%$

Resultados - Resumo

Classificador	Erro Médio	Intervalo de confiança de 95%
Fuzzy	0.464509 ¹	-
Bayesiano	0.245895	(0.239354 $\leq \mu \leq$ 0.252435) = 95%
k-vizinhos (k=15)	0.028421	(0.016759 $\leq \mu \leq$ 0.040083) = 95%
Regra da soma	0.102421	(0.092963 $\leq \mu \leq$ 0.111879) = 95%
MLP	0.075684	(0.066773 $\leq \mu \leq$ 0.084595) = 95%
SVM - kernel de base radial	0.123789	(0.118528 $\leq \mu \leq$ 0.129050) = 95%

Resultados - Comparação e Friedman teste

	Bayesiano	K-vizinhos	Soma	MLP	SVM
	ranking				
test 1	3	5	4	1	2
test 2	5	1	3	2	4
test 3	5	1	3	2	4
test 4	5	1	2	4	3
test 5	5	1	4	3	2
test 6	5	1	2.5	2.5	4
test 7	5	1	2	4	3
test 8	5	1	2	4	3
test 9	5	1	3	2	4
test 10	5	1	3.5	2	3.5
Média Rank	4.8	1.4	2.9	2.65	3.25

Resultados - Comparação e Friedman teste

	Bayesiano	K-vizinhos	Soma	MLP	SVM
Bayesiano					
K-vizinhos					
Soma					
MLP					
SVM					

Figura que compara os classificadores, os pontos marcados em azul significam que os classificadores são significativamente diferentes em relação ao outro.

Discussão/Conclusões

- Valores encontrados próximos da literatura.
- K-vizinhos aparece como melhor classificador
- Classificador Fuzzy aparece como pior classificador
- Refinamento dos parâmetros tornou resultados melhores (k-vizinhos, MLP)
- Estudo com limitações devido a base de dados utilizada
- Dificuldades no experimento devido ao tempo de computação de alguns algoritmos

Bibliografia

- [1] F. A. T. de Carvalho et al., "Relational Partitioning Fuzzy Clustering Algorithms Based on Multiple Dissimilarity Matrices". *Fuzzy Sets and Systems*, v. 215, p. 1-28, 2013.
- [2] T. M. Mitchell, *Machine learning*. Burr Ridge, IL: McGraw Hill, 1997.
- [3] A. P. Braga et al., *Redes neurais artificiais: teoria e aplicações*. 2 ed. Rio de Janeiro: LTC, 2007.
- [4] L. Hubert and P. Arabie, "Comparing partitions." *Journal of classification* 2, no. 1, 1985.
- [5] J. Demšar, "Statistical comparisons of classifiers over multiple data sets." *The Journal of Machine Learning Research* 7, 2006, pp. 1-30.
- [6] D. W. Aha, "Incremental constructive induction: An instance-based approach." In *Proceedings of the Eighth International Workshop on Machine Learning*, pp. 117-121. 1991.
- [7] C. J. Matheus and L. A. Rendell. "Constructive Induction On Decision Trees." In *IJCAI*, vol. 89, pp. 645-650, 1989.
- [8] C. J. Matheus, "Adding Domain Knowledge to SBL Through Feature Construction." In *AAAI*, pp. 803-808, 1990.